

Técnicas de aprendizado de máquina para a previsão da inflação brasileira medida pelo IPCA

Vinicius Limeira
UFAL PPGE *

Resumo

Este estudo tem como objetivo prever a inflação brasileira medida pelo IPCA, um índice de grande relevância na análise da conjuntura econômica e na tomada de decisões dos agentes de mercado. Foram utilizadas técnicas semelhantes à regressão linear, sendo as seguintes, Complete Subset Regression (CSR), Floresta Aleatória (Bagging) e LASSO, para obter previsões de curto prazo (1 passo à frente) e médio prazo (12 passos à frente). Além disso, dois modelos de referência - um passeio aleatório e a previsão do FOCUS obtida junto ao BACEN - foram considerados. Adicionalmente, foi explorada a combinação entre os modelos. Individualmente, o método CSR apresentou a melhor acurácia, enquanto a combinação teve impacto na redução do RMSE.

1 Introdução

A inflação, mensurada pelo IPCA (Índice de Preços ao Consumidor Amplo), é um indicador crucial na avaliação do cenário econômico, amplamente utilizado por instituições estatais e privadas para orientar processos decisórios. Bancos centrais, em particular, dependem das previsões de inflação não apenas para moldar políticas monetárias, mas também para ancorar expectativas e aprimorar a eficácia das políticas econômicas.

A importância da previsão da inflação transcende o âmbito das instituições financeiras, influenciando estratégias de investimento, como destacado por (IVERSEN *et al.*, 2016). Evidências indicam que modelos tradicionais, como aqueles derivados da curva de Phillips, podem não ser eficientes em ambientes ricos em dados (ATKESON; OHANIAN *et al.*, 2001). Além disso, esses modelos muitas vezes não superam previsões mais ingênuas.

No contexto brasileiro, estudos como o de (ARRUDA; FERREIRA; CASTELAR, 2011) exploraram diversos modelos lineares e não lineares, incluindo a curva de Phillips, para prever a inflação. Os resultados indicaram que alguns modelos não lineares e até

*

mesmo o simples modelo autoregressivo (AR) produziram erros de previsão menores que a abordagem tradicional.

Pode-se dizer que existe um contraste entre a abordagem econométrica tradicional, focada em encontrar o modelo que melhor explica a variável dependente (neste caso, a inflação), e a abordagem de aprendizado de máquina, onde o desenvolvimento do algoritmo visa a previsão eficiente, como é apontado por (ATHEY; IMBENS, 2019).

Este trabalho se inspira em contribuições significativas que utilizaram técnicas avançadas de aprendizado de máquina, que inclui os trabalhos de (BAYBUZA, 2018), (MANDALINCI, 2017), (GARCIA; MEDEIROS; VASCONCELOS, 2017) e (MEDEIROS et al., 2021). Essas referências proporcionam uma base sólida para a aplicação dessas técnicas no contexto brasileiro.

Além disso, serão exploradas técnicas que buscam combinar previsões de diversos métodos, visando aumentar a acurácia (ELLIOTT; GARGANO; TIMMERMANN, 2013); (HOLLAUER; ISSLER; NOTINI, 2008); (BERGE; BJORVATN; TUNGODDEN, 2015). Essa abordagem tem se mostrado eficaz na redução do erro de previsão.

2 Metodologia

As especificações de cada modelo estimado são definidas a seguir, utilizando como referência metodológica o trabalho de (HASTIE et al., 2009), que é um livro de destaque para o estudo dos algoritmos de aprendizagem de máquina, juntamente com as referências já citadas, como (GARCIA; MEDEIROS; VASCONCELOS, 2017) e (MEDEIROS et al., 2021). As variáveis a serem utilizadas são apresentadas na Tabela 1, foram selecionadas com base na revisão de literatura apresentada na introdução deste artigo. Buscando abranger diversas áreas da economia, como monetária, fiscal, financeira, mercado de trabalho e produção, optou-se por um conjunto de 33 variáveis exógenas, além do próprio IPCA. Essas variáveis compõem uma base mais ampla e expandida, incluindo de 1 a 4 defasagens, resultando, após as seleções descritas posteriormente, em um conjunto total de 159 variáveis potencialmente preditoras, o qual incorpora também dummies sazonais.

2.1 Método Empírico

Foi considerada uma abordagem de previsão direta, onde π_t representa a inflação no mês t , calculada como $\pi_t = \log(p_t) - \log(p_{t-1})$, onde p_t é o índice de preços no período t . Dessa forma, a inflação em π_{t+h} períodos a frente, é modelada como uma função de um conjunto preditores medidos no período t , tal como:

$$\pi_{t+h} = T(x) + u_{t+h} \quad (1)$$

onde $T(x)$ é um mapeamento possivelmente não linear de um conjunto de q preditores, u_{t+h} é o erro associado a previsão, $x_t = (x_{1t}, \dots, x_{qt})' \in X \subseteq R^q$, podendo incluir preditores fracamente exógenos, valores defasados da inflação e diversos fatores calculados a partir de um grande número de covariáveis potenciais. Para a maioria dos métodos considerados nesse trabalho, a especificação $T(x)$ é linear, de modo que:

$$\pi_{t+h} = \beta' x_t + u_{t+h} \quad (2)$$

onde $\beta \in R^q$ é um vetor de parâmetros desconhecidos.

2.2 Modelo LASSO

LASSO (Least Absolute Shrinkage and Selection Operator) é uma técnica de regularização que adiciona um termo de penalização a função custo da regressão linear, o termo de penalização é a soma absoluta dos coeficientes da regressão multiplicada por um parâmetro de ajuste λ (lambda). O estimador é semelhante ao de mínimos quadrados ordinários, é definido como:

$$\hat{\beta}^{lasso} = \min_{\beta} \left[\sum_{t=1}^T (\pi_{t+h} - \beta' x_t)^2 + \lambda \sum_{j=1}^q |\beta_j| \right] \quad (3)$$

da equação acima 3, percebe-se que o valor de λ é extremamente relevante para o resultado do modelo. Se esse parâmetro aumenta o viés do estimador também aumenta, se ele diminui, quem aumenta é a variância, caso seja 0, ele se torna igual ao estimador de MQO. Para achar o valor ótimo para λ , foi utilizado a técnica de validação cruzada.

2.3 Floresta Aleatória

A metodologia de floresta aleatória foi inicialmente proposta por (BREIMAN, 2001) como forma de reduzir a variância da árvore de regressão, e é baseada na agregação bootstrap (bagging) de árvores de regressão construídas aleatoriamente. Para compreender o funcionamento da árvore de regressão, consideremos um problema em que x_1 e x_2 são variáveis explicativas e Y uma variável dependente. Inicialmente, o espaço é dividido em regiões usando cortes em x_1 seguidos por cortes em x_2 . Essa abordagem gera uma partição em regiões, cada uma representada por um nó terminal em uma árvore. Cada nó terminal possui uma constante c_k , estimada pela média amostral das realizações de Y dentro dessa região. Isso resulta em uma representação eficaz e única da relação entre as variáveis, facilitando a compreensão do modelo.

Considerando a variável de inflação, π_{t+h} , e o conjunto de preditores x_t em um número de K nós terminais as divisões são determinadas para minimizar a soma dos quadrados, chega-se ao seguinte modelo:

$$\hat{\pi}_{t+h} = \sum_{k=1}^K c_k I_k(x_t : \theta_k) \quad (4)$$

em que $I_k((x_t, \theta_k))$ é um indicador tal que:

$$I_k(x_t, \theta_k) = \begin{cases} 1 & \text{se } x_t \in R_k(\theta_k) \\ 0 & \text{c.c} \end{cases}$$

O modelo floresta aleatória é uma coleção de árvores de regressão, cada uma especificada em uma amostra bootstrap da amostra original. Como estamos lidando com séries temporais, foi aplicado o método de bagging. Supondo que haja B amostras bootstrap para cada b , onde $b = 1, \dots, B$ em uma árvore com K_b regiões é estimada para

um subconjunto aleatório das regressões originais. A previsão final é a média de cada árvore aplicada aos dados originais.

$$\pi_{t+h} = \frac{1}{B} \sum_{b=1}^B \left(\sum_{k=1}^{K_b} \hat{c}_{k,b} I_{k,b}(x_t; \hat{\theta}_{k,b}) \right) \quad (5)$$

2.4 Complete Subset Regression (CSR)

Esse é um método relativamente novo e simples, apresentado por (ELLIOTT; GARGANO; TIMMERMAN, 2013), sendo bastante interessante para problemas com alta dimensionalidade. Nele são estimadas todas as regressões possíveis de combinações entre as variáveis preditoras, o que auxilia no controle do problema da multicolinearidade. Entretanto, estimar todas as combinações possíveis em 159 variáveis é intensivo computacionalmente, de forma que foi adotado o procedimento adotado semelhante ao de (GARCIA; MEDEIROS; VASCONCELOS, 2017), em que há um procedimento de "pré teste" com cada uma das variáveis estimadas em uma regressão simples contra o IPCA. Assim, são selecionadas as 20 variáveis com melhores valores na estatística t e com elas são estimadas todas as combinações possíveis de regressões com 15 parâmetros

É possível explorar o comportamento da inflação, além de outros aspectos relevantes associados a essa variável, em tempo real em (Conjuntura ipca). Além disso, é possível ainda observar o desempenho do modelo de previsão por meio de (modelo ipca).

Variáveis	Unidade	Fonte
IPCA	% a.m.	IBGE
Taxa de Câmbio	R\$/US\$	BCB
Interesse por "seguro desemprego"	índice	Google
Taxa de juros pré fixada	% a.a.	IPEADATA
PIB mensal	R\$ milhares	BCB
IGP-M (FGV)	% a.m.	BCB
IGP-DI (FGV)	% a.m.	BCB
Meios de pagamento - M1	R\$ mil	BCB
Meios de pagamento amplo - M2	R\$ mil	BCB
Meios de pagamento amplo - M3	R\$ mil	BCB
Meios de pagamento amplo - M4	R\$ mil	BCB
PIM-PF	% a.m.	IBGE
Encadeamento do antigo e novo CAGED	Pessoa	BCB
Balança de Pagamentos BPM6	US\$ milhares	BCB
Imposto sobre a renda (IR)	R\$ milhares	IPEADATA
Ibovespa	% a.m.	IPEADATA
volume de vendas PMC	% a.a.	IBGE
Vendas de veiculos (Fenabreve)	Automóvel	BCB
divida líquida do setor público	% PIB	BCB
Consumo de Energia (Eletrobrás)	GWh	IPEADATA
petróleo Bruto	US\$/barril	IPEADATA
expectativa de mercado ipca	% a.a.	Focus/BCB

Tabela 1 – Base de dados - Listade variáveis

3 Resultados

A figura 1 exibe da inflação anual no Brasil para o período de Jul/2007 a out/2023. A análise gráfica dessa variável aponta para uma pequena subida do índice, após uma queda forte, desde o começo de jan/2023.




Figura 1 – Inflação anual medida pelo ipca

A Tabela 2 exibe os valores do RMSE (*Root Mean Square Error*) para previsões de 12 meses à frente. Este estudo tem como propósito avaliar com maior precisão a acurácia dos modelos, uma vez que um período mais longo tende a revelar qual modelo apresenta a melhor acurácia. Nota-se que os maiores erros ocorrem nos modelos de referência, o Passeio Aleatório (Rw) e a previsão realizada pelo Focus. Este resultado era esperado, dado que o modelo Rw é o mais simples; entretanto, ele demonstra um desempenho superior à média do Focus, frequentemente considerado referência no mercado.

Os modelos de Bagging e Lasso exibem desempenhos semelhantes, sendo que, devido à complexidade computacional do Bagging, espera-se um erro menor. Os modelos que demonstraram o melhor desempenho foram o Ensemble (combinação) e o CSR, que parecem bastante satisfatórios em comparação aos demais.

Periodos	Modelo	RMSE
12	Lasso	0.30
12	csr	0.26
12	bagging	0.33
12	ensemble	0.28
12	rw	0.36
12	focus	0.39

Tabela 2 – RMSE para previsão 12 passos à frente

É possível observar como esses modelos se comportam ao longo do tempo através da figura 2, perceb-se que a tendência é que os modelos continuem tendo uma acurácia melhor que a média do mercado medida pelo Focus.




Figura 2 – RMSE para previsão 12 passos à frente

4 Considerações finais

Este estudo buscou desenvolver um modelo de previsão para a inflação brasileira medida pelo IPCA. Dada a importância dessa variável na conjuntura econômica, exploramos métodos que variam desde a econometria clássica, utilizando estimações da curva de Phillips, até abordagens mais modernas com o emprego de técnicas de aprendizado de máquina. Foram estimados três modelos, similares à regressão linear clássica: Complete Subset Regression (CSR), Floresta Aleatória (Bagging) e LASSO.

Todas as técnicas apresentaram desempenho satisfatório em comparação com os modelos de referência (Benchmark) - um baseado no modelo de Passeio Aleatório e outro na previsão do FOCUS pelo BCB. Notavelmente, a Complete Subset Regression (CSR) obteve o melhor desempenho, com um RMSE de 0.26. As variáveis explicativas consideradas no estudo incluíram IPCA (IBGE), Taxa de Câmbio (BCB), Interesse por "seguro desemprego" (Google), Taxa de juros pré-fixada (Ipea), PIB mensal (IBGE), IGP-M (FGV), IGP-DI (FGV), Meios de Pagamento M1 (BCB), Meios de Pagamento Amplo M2, M3 e M4 (BCB), Pim-pf (IBGE), Encadeamento do antigo e novo CAGED (BCB), Imposto sobre a Renda (Ipea), Ibovespa (Ipea), Volume de Vendas PMC (IBGE), Vendas de Veículos Fenabrave (Ipea), Dívida Líquida do Setor Público (BCB), Consumo de Energia Eletrobrás (Ipea), Petróleo Bruto (Ipea), e Expectativa de Mercado para o IPCA (Focus/BCB).

Os modelos demonstraram um bom desempenho em comparação aos modelos de referência (rw e focus). Destaca-se que os modelos CSR e Ensemble alcançaram os melhores resultados, com RMSE de 0.26 e 0.28, respectivamente. Contudo, a adição de novos modelos e técnicas seria bem-vinda, conforme é prática comum na literatura especializada.

Referências

- ARRUDA, E. F.; FERREIRA, R. T.; CASTELAR, I. Modelos lineares e não lineares da curva de phillips para previsão da taxa de inflação no brasil. *Revista Brasileira de Economia*, SciELO Brasil, v. 65, p. 237–252, 2011. Citado na página 1.
- ATHEY, S.; IMBENS, G. W. Machine learning methods that economists should know about. *Annual Review of Economics*, Annual Reviews, v. 11, p. 685–725, 2019. Citado na página 2.
- ATKESON, A.; OHANIAN, L. E. et al. Are phillips curves useful for forecasting inflation? *Federal Reserve bank of Minneapolis quarterly review*, Citeseer, v. 25, n. 1, p. 2–11, 2001. Citado na página 1.
- BAYBUZA, I. Inflation forecasting using machine learning methods. *Russian Journal of Money and Finance*, , v. 77, n. 4, p. 42–59, 2018. Citado na página 2.
- BERGE, L. I. O.; BJORVATN, K.; TUNGODDEN, B. Human and financial capital for microenterprise development: Evidence from a field and lab experiment. *Management Science*, INFORMS, v. 61, n. 4, p. 707–722, 2015. Citado na página 2.
- BREIMAN, L. Random forests. *Machine learning*, Springer, v. 45, p. 5–32, 2001. Citado na página 3.
- ELLIOTT, G.; GARGANO, A.; TIMMERMAN, A. Complete subset regressions. *Journal of Econometrics*, Elsevier, v. 177, n. 2, p. 357–373, 2013. Citado 2 vezes nas páginas 2 e 4.
- GARCIA, M. G.; MEDEIROS, M. C.; VASCONCELOS, G. F. Real-time inflation forecasting with high-dimensional models: The case of brazil. *International Journal of Forecasting*, Elsevier, v. 33, n. 3, p. 679–693, 2017. Citado 2 vezes nas páginas 2 e 4.
- HASTIE, T. et al. *The elements of statistical learning: data mining, inference, and prediction*. [S.l.]: Springer, 2009. v. 2. Citado na página 2.
- HOLLAUER, G.; ISSLER, J. V.; NOTINI, H. H. Prevendo o crescimento da produção industrial usando um número limitado de combinações de previsões. *Economia Aplicada*, SciELO Brasil, v. 12, p. 177–198, 2008. Citado na página 2.
- IVERSEN, J. et al. Real-time forecasting for monetary policy analysis: The case of sveriges riksbank. *Riksbank Research Paper Series*, n. 142, 2016. Citado na página 1.
- MANDALINCI, Z. Forecasting inflation in emerging markets: An evaluation of alternative models. *International Journal of Forecasting*, Elsevier, v. 33, n. 4, p. 1082–1104, 2017. Citado na página 2.
- MEDEIROS, M. C. et al. Forecasting inflation in a data-rich environment: the benefits of machine learning methods. *Journal of Business & Economic Statistics*, Taylor & Francis, v. 39, n. 1, p. 98–119, 2021. Citado na página 2.